ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH

ĐẠI HỌC CÔNG NGHỆ THÔNG TIN

KHOA KHOA HỌC MÁY TÍNH



Môn học: Học sâu và Ứng dụng trong kinh doanh
Lớp: IS6109.11.CH

Phân loại ý định mua hàng của người mua sắm trực tuyến

GVHD: Tạ Hoàng Thắng

Học viên:

Full Name	Student ID
Phạm Quốc Anh Khoa	250101090

Mục lục

1 Giới thiệu bài toán **2**

1.1 Bối cảnh thương mại điện tử và bài toán tối ưu tỷ lệ chuyển đổi 2

1.2 Vấn đề nghiên cứu và câu hỏi kinh doanh 2

1.3 Mục tiêu và phạm vi đề tài 2

1.4 Ý nghĩa ứng dụng thực tiễn trong doanh nghiệp 3

2 Bộ dữ liệu và phân tích khám phá dữ liệu (EDA) **3**

2.1 Tổng quan bộ dữ liệu Online Shoppers Purchasing Intention Dataset 3

2.2 Mô tả các biến 3

2.3 Thông tin bổ sung về các biến 5

2.4 Phân tích đơn biến 5

2.4.1 Phân tích nhãn `Revenue` và mất cân bằng dữ liệu 5

2.4.2 Phân phối lệch và giá trị ngoại lai 6

2.5 Phân tích đa biến 7

3 Phương pháp **10**

3.1 Phép biến đổi Log1p và chuẩn hóa Z-score 10

3.2 Feature Engineering 12

3.3 Các mô hình sử dụng trong thực nghiệm 14

3.3.1 Logistic Regression 14

3.3.2 XGBoost 14

3.3.3 Multilayer Perceptron (MLP) 15

3.4 Quy trình thực nghiệm 16

4 Evaluation Metrics **18**

5 Thực nghiệm **19**

5.1 Phân chia dataset 19

5.2 Cấu hình huấn luyện và siêu tham số (Hyperparameters) 19

5.2.1 Cấu hình Mạng PyTorch MLP 19

5.2.2 Cấu hình Logistic Regression (LR) 20

5.2.3 Cấu hình XGBoost (XGBClassifier) 20

5.3 Kết quả thực nghiệm 20

5.3.1 Phân tích quá trình hội tụ của MLP qua các phương pháp tiền xử lý . . 20

5.3.2 Thời gian huấn luyện 21

5.3.3 So sánh kết quả các mô hình 22

6 Kết luận **26**

6.1 Mức độ cải thiện và tính ổn định 26

6.2 Tác động của tiền xử lý và các nhóm đặc trưng 26

1 Giới thiệu bài toán

1.1 Bối cảnh thương mại điện tử và bài toán tối ưu tỷ lệ chuyển đổi

Trong kỷ nguyên số hóa hiện đại, ngành thương mại điện tử (E-Commerce) chứng kiến sự bùng nổ về lưu lượng truy cập của người dùng trên nền tảng web và ứng dụng di động. Tuy nhiên, một thực tế cốt lõi chi phối toàn bộ hoạt động tiếp thị số là: hầu hết người dùng truy cập website chỉ để tham khảo, so sánh giá hoặc lướt xem giải trí, và chỉ một tỷ lệ rất nhỏ thực sự đưa ra quyết định mua hàng cuối cùng.

Chi phí thu hút khách hàng mới qua các kênh quảng cáo trực tuyến (Google Ads, Facebook Ads, Affiliate) ngày càng leo thang. Nếu sàn thương mại điện tử đối xử với mọi lượt truy cập theo cùng một cách, doanh nghiệp sẽ lãng phí nguồn lực tiếp thị, phân bổ ngân sách khuyến mãi kém hiệu quả và làm giảm trải nghiệm người dùng với các quãng cáo không đúng lúc, đúng người.

1.2 Vấn đề nghiên cứu và câu hỏi kinh doanh

Nhận diện sớm ý định mua hàng (Online Shoppers' Purchasing Intention) của khách hàng ngay trong phiên duyệt web là chìa khóa then chốt để tối ưu hóa tỷ lệ chuyển đổi (Conversion Rate Optimization - CRO) và tối đa hóa giá trị vòng đời khách hàng. Từ bài toán kinh doanh thực tế, nghiên cứu đặt ra các câu hỏi cốt lõi:

1. Những đặc trưng hành vi và tín hiệu kỹ thuật số nào trong một phiên truy cập phản ánh rõ ràng nhất quyết định mua sắm của khách hàng?

2. Dữ liệu clickstream mang tính mất cân bằng nghiêm trọng và phân phối lệch chuẩn cực đoan. Làm thế nào để xử lý dữ liệu và tạo lập đặc trưng mới (Feature Engineering) nhằm tối ưu khả năng nhận diện lớp thiểu số (khách chốt đơn)?

3. Giữa mô hình tuyến tính truyền thống (Logistic Regression), mô hình cây quyết định (XGBoost) và mô hình học sâu (Deep Multilayer Perceptron - MLP), kiến trúc nào biểu diễn tốt nhất mối quan hệ giữa các đặc trưng hành vi với quyết định mua hàng?

1.3 Mục tiêu và phạm vi đề tài

Mục tiêu kỹ thuật: Dựa trên các đặc trưng hành vi và thông tin bối cảnh của phiên truy cập, xây dựng hệ thống mô hình học máy và học sâu có khả năng phân loại nhị phân chính xác trạng thái: "Có mua hàng" (Revenue = True) hoặc "Không mua hàng" (Revenue = False).

Mục tiêu phương pháp luận:

1. Đánh giá ảnh hưởng của tỷ lệ giá trị bằng 0 cao (High Proportion of Zero Values) và phân phối đuôi dài (Heavy-tailed Distribution).

2. Đề xuất chuỗi biến đổi toán học Log1p và Z-score kết hợp các kỹ thuật khai phá đặc trưng miền kinh doanh (FE1 đến FE4).

3. Triển khai quy trình kiểm chứng chéo lặp phân tầng nghiêm ngặt (Repeated Stratified K-Fold) nhằm đảm bảo tính ổn định và khả năng tổng quát hóa tuyệt đối của mô hình.

1.4 Ý nghĩa ứng dụng thực tiễn trong doanh nghiệp

Việc phân loại chính xác ý định mua sắm theo thời gian thực mang lại lợi ích kép:

1. **Phân phối mã giảm giá và quà tặng:** Xây dựng chiến lược phân phối mã giảm giá và quà tặng phù hợp với từng nhóm khách hàng, dựa trên hành vi và mức độ tiềm năng mua hàng, nhằm gia tăng tỷ lệ chuyển đổi và tối ưu hiệu quả khuyến mãi.

2. **Tối ưu hóa ngân sách tiếp thị:** Hạn chế phân phối mã giảm giá và quà tặng cho những khách hàng vốn đã có ý định mua hàng cao, đồng thời tập trung nguồn lực khuyến mãi vào nhóm khách hàng cần thêm động lực để đưa ra quyết định mua hàng.

2 Bộ dữ liệu và phân tích khám phá dữ liệu (EDA)

2.1 Tổng quan bộ dữ liệu Online Shoppers Purchasing Intention Dataset

Nghiên cứu sử dụng bộ dữ liệu chuẩn học máy quốc tế Online Shoppers Purchasing Intention Dataset, được công bố trên kho lưu trữ dữ liệu Machine Learning của Đại học California, Irvine (UCI Machine Learning Repository).

- **Quy mô tập mẫu:** Gồm 12.330 phiên truy cập (sessions) độc lập.
- **Đơn vị quan sát:** Mỗi phiên truy cập đại diện cho tương tác của một người dùng trên sàn thương mại điện tử. Dữ liệu được thu thập xuyên suốt một năm để phản ánh đầy đủ tính chu kỳ và mùa vụ.
- **Cấu trúc dữ liệu:** Gồm 17 đặc trưng đầu vào (features) và 1 nhãn mục tiêu nhị phân (Revenue).
- **Giá trị thiếu:** Không ghi nhận giá trị thiếu (Missing values = 0 trên toàn bộ các cột).

2.2 Mô tả các biến

Bộ dữ liệu gồm 10 thuộc tính số và 8 thuộc tính phân loại. Biến `Revenue` được sử dụng làm nhãn lớp mục tiêu. Bảng 2.1 trình bày vai trò, kiểu dữ liệu và ý nghĩa của từng biến; không biến nào có giá trị thiếu.

Bảng 2.1: Mô tả các biến trong bộ dữ liệu

Tên biến	**Vai trò**	**Kiểu dữ liệu**	**Mô tả**	**Thiếu**
`Administrative`	Đặc trưng	Số nguyên	Số trang thuộc nhóm quản trị mà người dùng truy cập trong phiên.	Không
`Administrative_ Duration`	Đặc trưng	Số nguyên	Tổng thời gian người dùng dành cho các trang thuộc nhóm quản trị trong phiên.	Không
`Informational`	Đặc trưng	Số nguyên	Số trang cung cấp thông tin mà người dùng truy cập trong phiên.	Không
`Informational_ Duration`	Đặc trưng	Số nguyên	Tổng thời gian người dùng dành cho các trang cung cấp thông tin trong phiên.	Không
`ProductRelated`	Đặc trưng	Số nguyên	Số trang liên quan đến sản phẩm mà người dùng truy cập trong phiên.	Không
`ProductRelated_ Duration`	Đặc trưng	Liên tục	Tổng thời gian người dùng dành cho các trang liên quan đến sản phẩm trong phiên.	Không
`BounceRates`	Đặc trưng	Liên tục	Tỷ lệ khách truy cập vào trang rồi rời website mà không tạo thêm yêu cầu nào đến máy chủ phân tích trong phiên.	Không
`ExitRates`	Đặc trưng	Liên tục	Với một trang cụ thể, tỷ lệ lượt xem trang mà trang đó là trang cuối cùng trong phiên.	Không
`PageValues`	Đặc trưng	Số nguyên	Giá trị trung bình của trang mà người dùng đã truy cập trước khi hoàn tất một giao dịch thương mại điện tử.	Không
`SpecialDay`	Đặc trưng	Số nguyên	Mức độ gần với một ngày đặc biệt (chẳng hạn ngày Valentine), khi phiên truy cập có khả năng dẫn đến giao dịch cao hơn. Giá trị được xác định dựa trên khoảng cách thời gian giữa ngày đặt hàng và ngày giao hàng.	Không
`Month`	Đặc trưng	Phân loại	Tháng trong năm diễn ra lượt truy cập.	Không
`OperatingSystems`	Đặc trưng	Số nguyên	Mã định danh hệ điều hành được sử dụng để truy cập website.	Không
`Browser`	Đặc trưng	Số nguyên	Mã định danh trình duyệt được sử dụng để truy cập website.	Không
`Region`	Đặc trưng	Số nguyên	Mã định danh khu vực địa lý của người truy cập.	Không
`TrafficType`	Đặc trưng	Số nguyên	Mã loại nguồn lưu lượng đưa người dùng đến website.	Không
`VisitorType`	Đặc trưng	Phân loại	Phân loại khách truy cập là khách mới hoặc khách quay lại.	Không
`Weekend`	Đặc trưng	Nhị phân	Cho biết ngày truy cập có phải là ngày cuối tuần hay không.	Không
`Revenue`	Mục tiêu	Nhị phân	Cho biết phiên truy cập có hoàn tất giao dịch mua hàng hay không.	Không

2.3 Thông tin bổ sung về các biến

Nhóm biến về trang quản trị, thông tin và sản phẩm ghi nhận số trang người dùng truy cập trong từng nhóm cùng tổng thời gian dành cho các trang đó. Các giá trị được suy ra từ URL của những trang đã truy cập và cập nhật theo thời gian thực khi người dùng thực hiện hành động, chẳng hạn chuyển từ trang này sang trang khác.

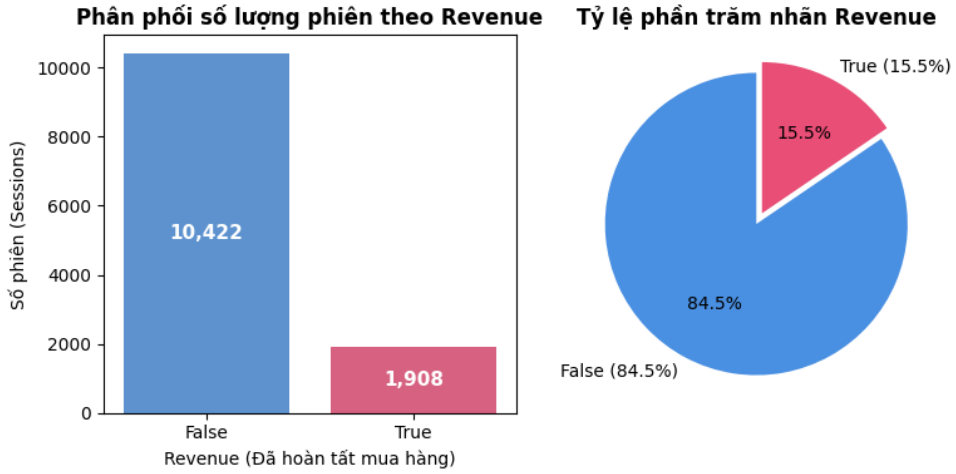
Các biến `BounceRates`, `ExitRates` và `PageValues` là những chỉ số đo lường của Google Analytics cho các trang trong website thương mại điện tử. Với biến `SpecialDay`, giá trị có thể thay đổi theo mức độ gần của ngày truy cập với dịp đặc biệt. Ví dụ, quanh dịp Valentine, biến này nhận giá trị khác 0 trong khoảng từ ngày 2 đến ngày 12 tháng 2, đạt giá trị lớn nhất là 1 vào ngày 8 tháng 2, và bằng 0 ở các ngày trước hoặc sau khoảng này, trừ khi ngày truy cập gần một dịp đặc biệt khác.

Ngoài các biến hành vi trên, bộ dữ liệu còn ghi nhận hệ điều hành, trình duyệt, khu vực, loại lưu lượng truy cập, loại khách truy cập (khách mới hoặc khách quay lại), tháng trong năm và thông tin cho biết ngày truy cập có rơi vào cuối tuần hay không.

2.4 Phân tích đơn biến

2.4.1 Phân tích nhãn `Revenue` và mất cân bằng dữ liệu

Hiện trạng dữ liệu: Dữ liệu mất cân bằng nghiêm trọng: 84.5% phiên không mua hàng (10.422 phiên), trong khi 15.5% phiên có mua hàng (1.908 phiên).



Hình 2.4.1: Phân bố số phiên truy cập theo nhãn Revenue

Hệ quả - Thách thức: Nếu một mô hình chỉ dự đoán tất cả phiên đều "Không mua" vẫn đạt Accuracy 84.5%, nhưng lại không có giá trị thực tiễn vì không phát hiện được bất kì người mua hàng nào.

Giải pháp kỹ thuật:

- **Chia tách dữ liệu:** Sử dụng `StratifiedKFold` và tham số `stratify=y` khi chia tập huấn luyện/kiểm tra để duy trì tỷ lệ lớp mua hàng khoảng 15.5% trong các fold.

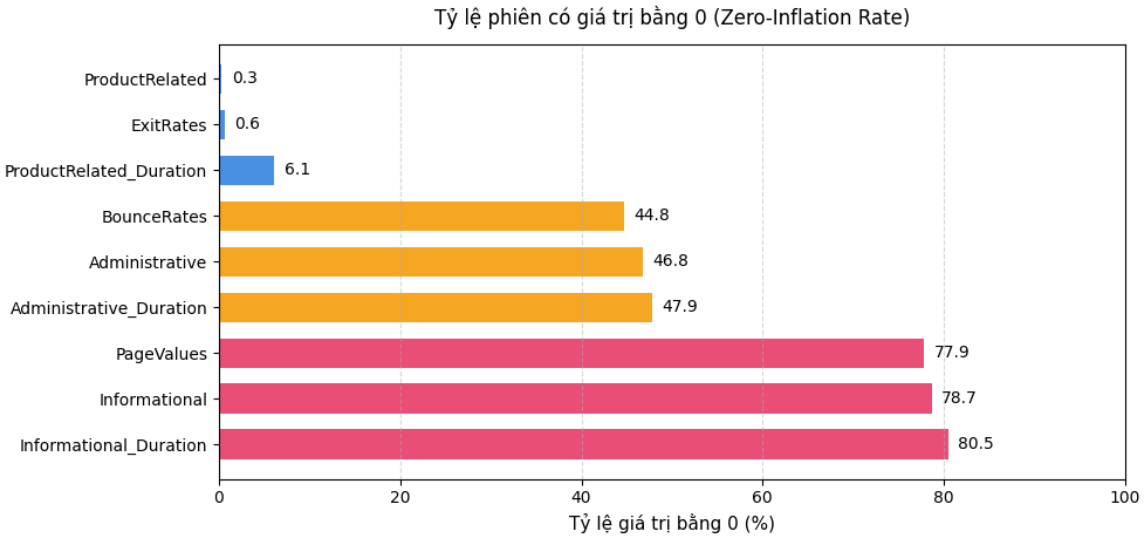
- **Chuẩn đo lường:** Không dùng Accuracy làm tiêu đáng giá, độ đo chính. Thay vào đó cần các độ đo khác phù hợp (được trình bày ở phần độ đo)

2.4.2 Phân phối lệch và giá trị ngoại lai

Bảng 2.2 trình bày các thống kê mô tả của 9 biến số. Các biến đếm trang thông tin, thời lượng truy cập nhóm thông tin và giá trị trang đều có Q1, trung vị và Q3 bằng 0, trong khi Mean và Max lớn hơn 0. Điều này cho thấy nhiều phiên có giá trị thấp hoặc bằng 0, nhưng vẫn có một số phiên mang giá trị rất cao.

Bảng 2.2: Thống kê mô tả các biến số trong bộ dữ liệu

Tên biến	**Mean**	**Min**	**25% (Q1)**	**Median**	**75% (Q3)**	**Max**
Administrative	2.32	0.00	0.00	1.00	4.00	27.00
Administrative_Duration	80.82	0.00	0.00	7.50	93.26	3,398.75
Informational	0.50	0.00	0.00	0.00	0.00	24.00
Informational_Duration	34.47	0.00	0.00	0.00	0.00	2,549.38
ProductRelated	31.73	0.00	7.00	18.00	38.00	705.00
ProductRelated_Duration	1,194.75	0.00	184.14	598.94	1,464.16	63,973.52
BounceRates	0.02	0.00	0.00	0.00	0.02	0.20
ExitRates	0.04	0.00	0.01	0.03	0.05	0.20
PageValues	5.89	0.00	0.00	0.00	0.00	361.76



Hình 2.4.2: Tỷ lệ giá trị bằng 0 của các biến

Các khoảng cách lớn giữa trung vị, giá trị trung bình và cực đại cho thấy phân phối lệch phải và có đuôi dài. Chẳng hạn, `ProductRelated_Duration` có trung vị 598.94, Q_3 là 1,464.16 và Max lên tới 63,973.52 giây (khoảng 17.7 giờ). Tương tự, `Administrative_Duration` có trung vị 7.50 nhưng Max là 3,398.75; `ProductRelated` có Q_3 bằng 38 nhưng Max bằng 705.

Đáng chú ý, dữ liệu xuất hiện hiện tượng tập trung số 0 lớn (Zero-Inflation). Tiêu biểu, `PageValues` có tới 77.86% và `Informational_Duration` có 80.49% giá trị bằng 0. Tỷ lệ số 0

chiếm đa số này khiến cả Q_1, trung vị và Q_3 của các biến này đều bằng 0.00, trong khi Max vẫn rất lớn (`PageValues` đạt 361.76; `Informational_Duration` đạt 2,549.38).

Sự kết hợp giữa tỷ lệ số 0 áp đảo ($> 77\%$) và các giá trị cực đại kéo giá trị trung bình lệch xa khỏi trung vị, làm biến dạng thang đo khoảng cách và gây khó khăn cho việc hội tụ của các mô hình nhạy cảm với phân phối như Logistic Regression và MLP nếu không có bước tiền xử lý phù hợp.

Định hướng kỹ thuật: Các giá trị ngoại lai cực lớn không nên bị xem là nhiễu cần loại bỏ, vì chúng có thể đại diện cho khách hàng tiềm năng dành nhiều thời gian tìm hiểu sản phẩm. Tuy nhiên, nếu giữ nguyên dữ liệu thô, chúng có thể ảnh hưởng đến hiệu năng phân lớp của Logistic Regression và MLP. Vì vậy, ở Chương 3 sẽ áp dụng phép biến đổi log1p, $x' = \ln(1+x)$, kết hợp với `StandardScaler`.

2.5 Phân tích đa biến

- **Tác động của PageValues (PV):** Dữ liệu cho thấy sự phân hóa rõ rệt theo PageValues: khi $PV = 0$ (chiếm đa số với 9,600 phiên), tỷ lệ mua hàng chỉ đạt 3.85%. Ngược lại, khi $PV > 0$, tỷ lệ mua tăng lên nhanh và đáng kể.

  Khi phân tầng nhóm $PV > 0$ thành 3 bậc bằng nhau (mỗi bậc 910 phiên), tỷ lệ chuyển đổi tăng dần: từ 38.13% ở mức Thấp (0.04–9.7), lên 55.05% ở mức Trung bình (9.7–27.0), và đạt 75.82% ở mức Cao (> 27.0), như minh họa trong Hình 2.5.1.

  Đồng thời, trong nhóm $PV > 0$, trung vị PageValues của khách chốt đơn (`Revenue=True`) là 22.97, cao hơn gấp đôi so với nhóm không mua (10.46).

- **Tác động của ExitRates và BounceRates:**

  Về phân phối tổng thể (Boxplot): Khách hàng có mua hàng (`Revenue=True`) duy trì tỷ lệ thoát (`ExitRates`) và bỏ trang (`BounceRates`) thấp hơn rõ rệt so với nhóm không mua. Cụ thể, trung vị của `ExitRates` ở nhóm mua hàng chỉ là 0.0160 (so với 0.0286 của nhóm không mua), và mốc phân vị 75% (Q_3) chỉ đạt 0.0250 (thấp hơn cả trung vị nhóm không mua). Đối với `BounceRates`, nhóm mua hàng có trung vị bằng tuyệt đối 0.0000 và giá trị trung bình chỉ 0.0051 (thấp hơn gần 5 lần so với mức 0.0253 ở nhóm không mua). Phân phối được minh họa trong Hình 2.5.2.

  Về quy luật suy giảm chuyển đổi (Barplot): Tỷ lệ mua hàng suy giảm dốc đứng khi tỷ lệ thoát tăng dần qua 5 bậc ngũ phân vị của `ExitRates`, từ mức đỉnh 27.21% (ở Q_1) rơi thẳng xuống chỉ còn 2.24% (ở Q_5). Đối với `BounceRates`, tỷ lệ chuyển đổi đạt cao nhất ở nhóm có tỷ lệ nảy rất nhỏ (T_1: 23.49%) và nhóm không bỏ trang (Bounce = 0: 18.77%), sau đó giảm mạnh về mức đáy 1.94% tại nhóm nảy cao nhất (T_4). Điều này chỉ ra người mua thực tế luôn có xu hướng duyệt web liền mạch và ít rời trang đột ngột. Về quy mô nhóm, `ExitRates` được chia thành 5 bậc có số phiên gần bằng nhau, mỗi bậc khoảng 2.465 phiên. Với `BounceRates`, có 5.518 phiên (khoảng 45%) mang giá trị bằng 0, được tô màu xanh lá trên biểu đồ; số phiên còn lại được chia thành 4 bậc, mỗi bậc khoảng 1.700 phiên. Quy luật chuyển đổi theo các nhóm tỷ lệ được minh họa trong Hình 2.5.3.

- **Tác động của khách mới và khách cũ:** Phân tích kết hợp loại khách hàng và yếu tố mùa vụ cho thấy sự khác biệt giữa tỷ lệ chuyển đổi và số đơn hàng thực tế.

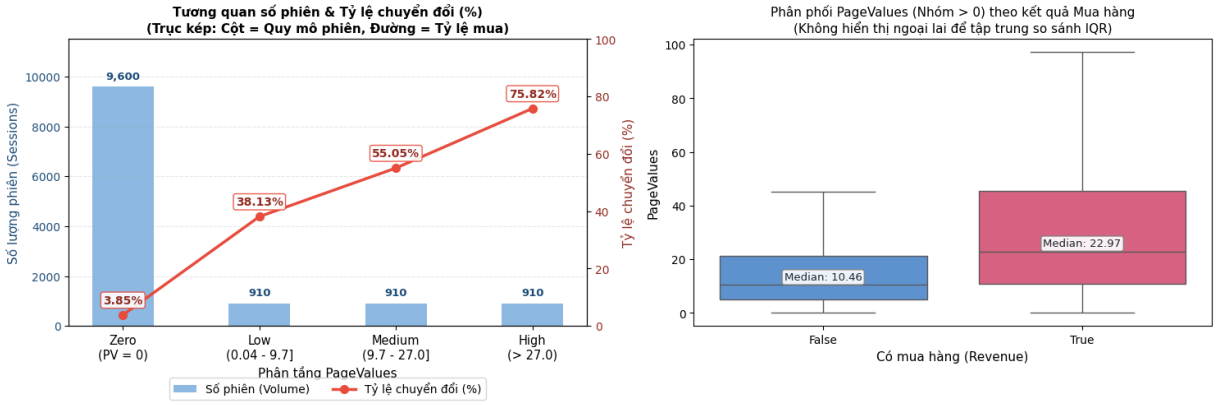
  Về tỷ lệ chuyển đổi: Trong các tháng, khách mới (`New_Visitor`) thường có tỷ lệ chuyển đổi cao hơn khách cũ (`Returning_Visitor`), dao động từ 15.5% đến 30.6%, so với 8.6%–24.6% ở khách cũ. Riêng tháng 2 chỉ có một phiên khách mới nên tỷ lệ của tháng này không đại diện để so sánh. Vào mùa cao điểm, khoảng cách thu hẹp rõ rệt: tháng 10 đạt 22.6% so với 20.5%, còn tháng 11 đạt đỉnh lần lượt 30.6% và 24.6% (Hình 2.5.4).

  Về số lượng đơn hàng thực tế (Conversions): Dù tỷ lệ chuyển đổi thấp hơn, khách cũ vẫn là nhóm đóng góp chủ lực, tạo ra khoảng 77% tổng số đơn hàng. Tháng 11 ghi nhận 757 đơn, gồm 629 đơn từ khách cũ và 128 đơn từ khách mới. Đây là mức cao nhất trong năm và hơn gấp đôi tháng 5, tháng có tổng số đơn cao thứ hai với 365 đơn (277 từ khách cũ và 88 từ khách mới).

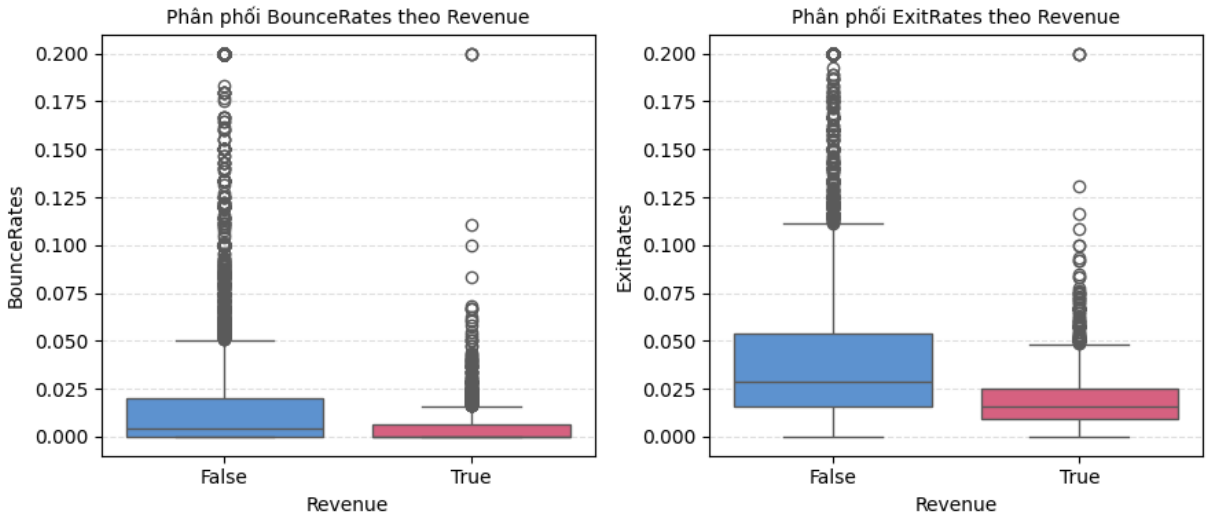
- **Tác động ngày trong tuần:** Phân tích cho thấy sự khác biệt giữa tỷ lệ chuyển đổi và số lượng đơn hàng thực tế.

  Về tỷ lệ chuyển đổi: Cuối tuần (`Weekend=True`) thường có tỷ lệ mua hàng cao hơn ngày thường ở đa số các tháng. Chênh lệch thể hiện rõ vào tháng 3 (13.51% so với 8.91%), tháng 5 (13.85% so với 10.04%) và tháng 9 (22.92% so với 18.18%). Riêng tháng 11, tỷ lệ mua duy trì ở mức cao cả ngày thường lẫn cuối tuần, lần lượt là 24.92% và 26.55%, cho thấy nhu cầu mua sắm cao điểm diễn ra xuyên suốt tuần.

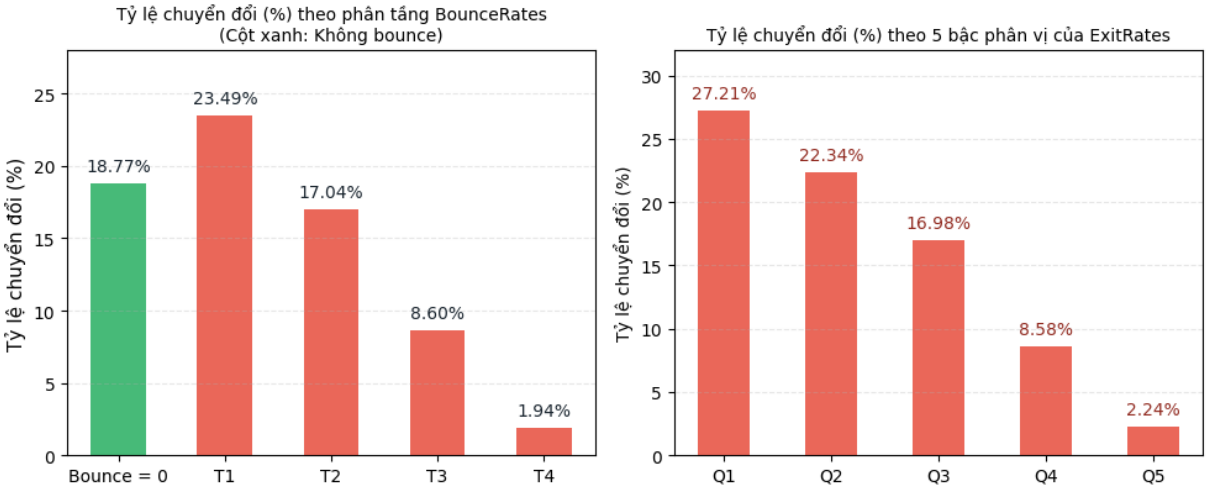
  Về số lượng đơn hàng thực tế (Conversions): Do ngày thường chiếm 5 ngày trong tuần, so với 2 ngày cuối tuần, ngày thường tạo ra 74% tổng số đơn hàng (1,409 đơn so với 499 đơn cuối tuần). Tháng 11 ghi nhận số đơn cao nhất với 760 đơn: ngày thường đóng góp 550 đơn, còn cuối tuần đóng góp 210 đơn (Hình 2.5.5).



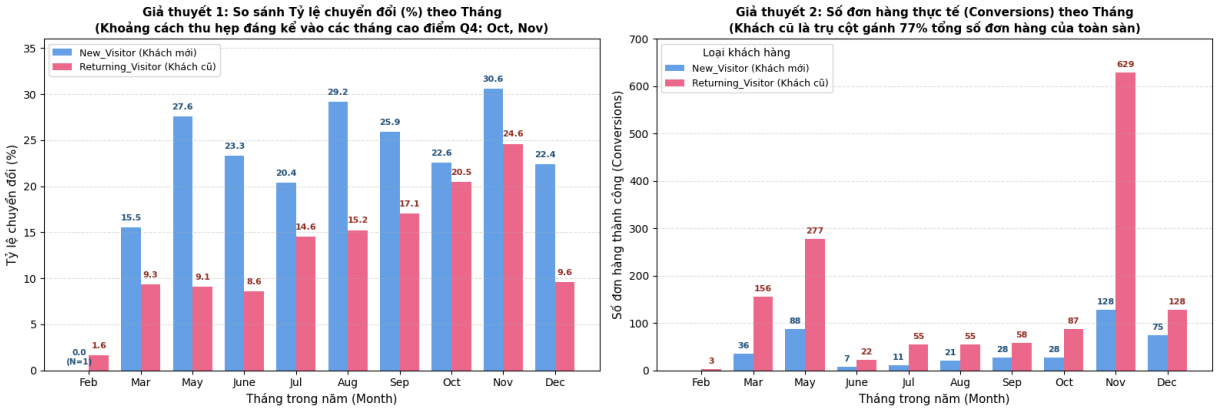
Hình 2.5.1: Quy mô phiên và tỷ lệ chuyển đổi theo nhóm PageValues; phân phối PageValues theo kết quả mua hàng



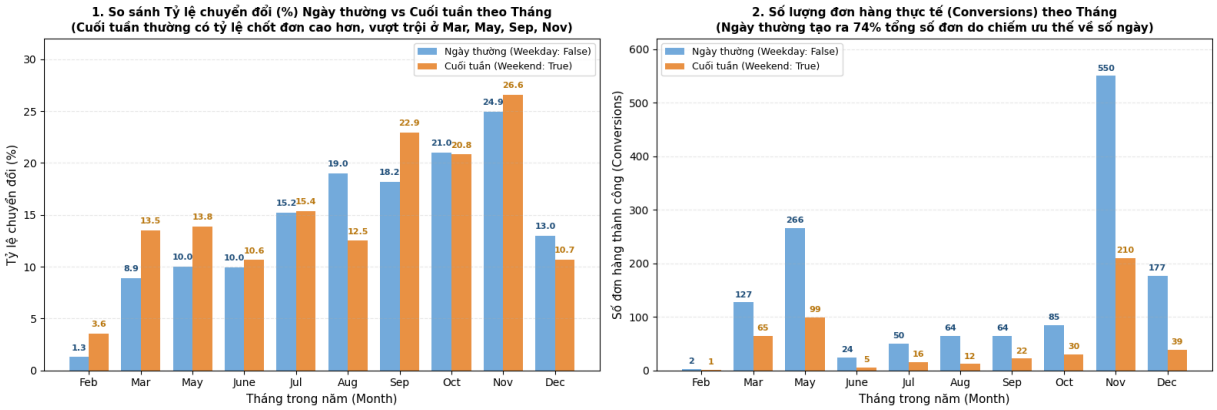
Hình 2.5.2: Phân phối ExitRates và BounceRates theo trạng thái mua hàng (Boxplot)



Hình 2.5.3: Tỷ lệ chuyển đổi theo các nhóm ExitRates và BounceRates (Barplot)



Hình 2.5.4: Tỷ lệ chuyển đổi và số đơn hàng theo tháng, phân tách theo loại khách truy cập



Hình 2.5.5: Tỷ lệ chuyển đổi và số đơn hàng theo tháng, phân tách theo ngày thường và cuối tuần

3 Phương pháp

3.1 Phép biến đổi Log1p và chuẩn hóa Z-score

Như đã phân tích tại Mục 2.4.2, các biến số lượng có độ lệch dương rõ rệt và khoảng giá trị trải rộng. Để hạn chế ảnh hưởng của các giá trị ngoại lai đến quá trình huấn luyện mô hình, cần có bước tiền xử lý dữ liệu.

Phép biến đổi logarit cơ số tự nhiên (Log1p):

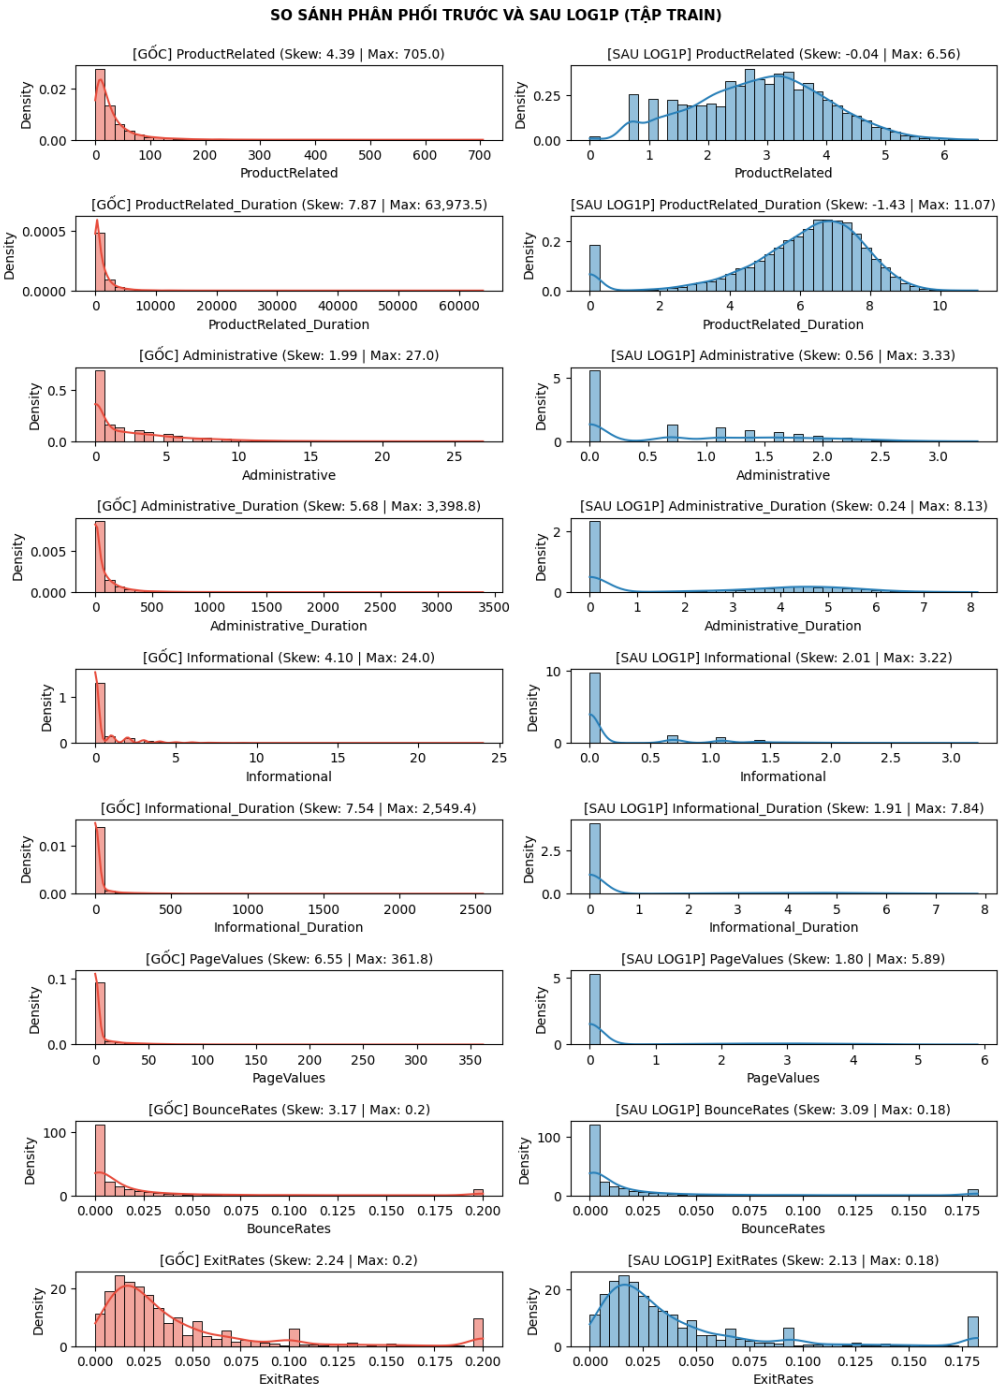
$$x' = \ln(1 + x) \tag{1}$$

Việc cộng 1 trước khi lấy logarit đảm bảo phép biến đổi hợp lệ với các giá trị $x = 0$, vốn chiếm tỷ trọng lớn trong dữ liệu. Hiệu quả giảm độ lệch trên tập huấn luyện thể hiện qua một số biến tiêu biểu: So sánh phân phối trước và sau biến đổi Log1p của các biến số được minh họa trong Hình 3.1.1. Hiệu quả của phép biến đổi không đồng đều giữa các biến, mà phụ thuộc vào miền giá trị và mức độ lệch ban đầu:

- **Nhóm biến được cải thiện rõ rệt:** Các biến đo lường quy mô và thời lượng duyệt web có khoảng giá trị rộng, lệch phải mạnh. Sau Log1p, đuôi dài được nén đáng kể và một số phân phối tiệm cận dạng chuông hơn:
  - `ProductRelated`: độ lệch giảm từ 4.39 xuống −0.04, còn giá trị cực đại giảm từ 705.0 xuống 6.56.
  - `ProductRelated_Duration`: độ lệch giảm từ 7.87 xuống −1.43, còn giá trị cực đại giảm từ 63,973.5 xuống 11.07, tức được nén hơn 5,700 lần.
  - `Administrative_Duration`: độ lệch giảm từ 5.68 xuống 0.24, còn giá trị cực đại giảm từ 3,398.8 xuống 8.13.
  - `Administrative`: độ lệch giảm từ 1.99 xuống 0.56, còn giá trị cực đại giảm từ 27.0 xuống 3.33.

– `PageValues`: độ lệch giảm từ 6.55 xuống 1.80, còn giá trị cực đại giảm từ 361.8 xuống 5.89.

- **Nhóm biến thay đổi ít:** `BounceRates` và `ExitRates` vốn chỉ nằm trong khoảng $[0, 0.2]$, nên phép biến đổi hầu như không làm thay đổi hình dạng phân phối. Độ lệch của `BounceRates` giảm nhẹ từ 3.17 xuống 3.09, giá trị cực đại từ 0.20 xuống 0.18; với `ExitRates`, các giá trị tương ứng là 2.24 xuống 2.13 và 0.20 xuống 0.18.



Hình 3.1.1: So sánh phân phối các biến số trước và sau phép biến đổi Log1p trên tập huấn luyện

Chuẩn hóa `StandardScaler`:

$$z = \frac{x - \mu}{\sigma} \tag{2}$$

Các biến cần được chuẩn hóa `StandardScaler`, trong đó mỗi giá trị được chuyển đổi dựa trên giá trị trung bình và độ lệch chuẩn của biến tương ứng. Phép biến đổi này giúp đưa các biến về cùng thang đo, với giá trị trung bình bằng 0 và độ lệch chuẩn bằng 1, hạn chế sự chênh lệch về quy mô giữa các đặc trưng. Quy trình tiền xử lý được lựa chọn theo đặc điểm phân phối của từng biến:

- **Biến lệch phải mạnh hoặc có đuôi dài:** Áp dụng Log1p trước để thu hẹp khoảng giá trị, sau đó dùng `StandardScaler` để chuẩn hóa. Nhóm này gồm `Administrative`, `Administrative_Duration`, `ProductRelated`, `ProductRelated_Duration` và `PageValues`.
- **Biến tỷ lệ có miền giá trị hẹp:** Bỏ qua bước Log1p và chuẩn hóa trực tiếp bằng `StandardScaler`. Ví dụ, `BounceRates` và `ExitRates` nằm trong khoảng $[0, 0.2]$; do giá trị vốn nhỏ, Log1p gần như không làm thay đổi phân phối của chúng.

3.2 Feature Engineering

Để bổ sung thông tin hành vi cho các mô hình, nghiên cứu xây dựng 9 đặc trưng mới từ dữ liệu phiên truy cập như sau:

1. `Has_PageValues`**:** Được xác định bằng công thức

$$\texttt{Has_PageValues} = \texttt{PageValues} > 0.$$

Đặc trưng này phân tầng khách hàng, tách nhóm có tiềm năng chốt đơn cao với nhóm chưa tạo giá trị (PV = 0).

2. `PV_per_TotalPages`**:** Được xác định bằng công thức

$$\texttt{PV_per_TotalPages} = \frac{\texttt{PageValues}}{\texttt{Total_Pages} + 1},$$

trong đó

$$\texttt{Total_Pages} = \texttt{Administrative} + \texttt{Informational} + \texttt{ProductRelated}.$$

Đặc trưng biểu thị mật độ giá trị trên mỗi trang. Tỷ số cao cho thấy khách duyệt web tập trung, có chủ đích mua rõ ràng, không lan man.

3. `PV_per_Duration`**:** Được xác định bằng công thức

$$\texttt{PV_per_Duration} = \frac{\texttt{PageValues}}{\texttt{ProductRelated_Duration} + 1}.$$

Đặc trưng đo giá trị tích lũy trên mỗi giây xem hàng, phản ánh tốc độ sinh giá trị và khả năng quyết định chốt đơn nhanh chóng.

4. `PV_to_ExitRate`**:** Được xác định bằng công thức

$$\texttt{PV_to_ExitRate} = \frac{\texttt{PageValues}}{\texttt{ExitRates} + 0.001}.$$

Đặc trưng đo lường quyết tâm hoàn tất đơn hàng so với rủi ro khách rời bỏ trang.

5. `PV_x_NewVisitor`**:** Được xác định bằng công thức

$$\texttt{PV_x_NewVisitor} = \texttt{PageValues} \times (\texttt{VisitorType} = \texttt{'New_Visitor'}).$$

Đặc trưng nhận diện nhóm khách mới nhưng đã vào thẳng trang sinh giá trị cao để mua ngay, thể hiện nhu cầu mua cấp bách.

6. `ProdDur_to_ExitRate`**:** Được xác định bằng công thức

$$\texttt{ProdDur_to_ExitRate} = \frac{\texttt{ProductRelated_Duration}}{\texttt{ExitRates} + 0.001}.$$

Đặc trưng phản ánh mức độ gắn kết ở nhóm PV = 0. Khách xem hàng lâu nhưng ít thoát trang có thể đang cân nhắc mua kỹ lưỡng.

7. `Avg_Dur_per_Page`**:** Được xác định bằng công thức

$$\texttt{Avg_Dur_per_Page} = \frac{\texttt{Total_Duration}}{\texttt{Total_Pages} + 1},$$

trong đó

$$\begin{aligned}\texttt{Total_Duration} = {} & \texttt{Administrative_Duration} \\ & + \texttt{Informational_Duration} \\ & + \texttt{ProductRelated_Duration}.\end{aligned}$$

Đặc trưng đo thời gian dừng chân trung bình trên mỗi trang, giúp phân biệt giữa hành vi lướt xem hời hợt và đọc kỹ chi tiết.

8. `Admin_per_TotalPages`**:** Được xác định bằng công thức

$$\texttt{Admin_per_TotalPages} = \frac{\texttt{Administrative}}{\texttt{Total_Pages} + 1}.$$

Đặc trưng biểu thị tỷ trọng trang quản trị, có thể là tín hiệu khách đang tương tác với tài khoản, giỏ hàng hoặc các bước trước thanh toán.

9. `Month_x_HasPV`**:** Được xác định bằng cách kết hợp tháng truy cập với trạng thái kích hoạt giá trị:

$$\texttt{Month_x_HasPV} = \texttt{Month} + \texttt{'_has_pv_'} + \texttt{Has_PageValues}.$$

Ví dụ: `Nov_has_pv_1` hoặc `May_has_pv_0`. Đặc trưng thể hiện bối cảnh mùa vụ kết hợp với trạng thái kích hoạt giá trị.

3.3 Các mô hình sử dụng trong thực nghiệm

Trong thực nghiệm, nghiên cứu đánh giá và so sánh ba mô hình phân loại thuộc các nhóm phương pháp khác nhau:

- **Logistic Regression:** Mô hình phân loại tuyến tính
- **XGBoost:** Mô hình tổ hợp dựa trên cây quyết định, lần lượt kết hợp nhiều cây để học các quan hệ phi tuyến và tương tác giữa các đặc trưng.
- **Multilayer Perceptron (MLP):** Mô hình học sâu gồm các lớp nơ-ron kết nối đầy đủ, có khả năng học biểu diễn phi tuyến từ các đặc trưng đầu vào.

Việc lựa chọn ba mô hình này cho phép đối chiếu hiệu quả giữa phương pháp tuyến tính, mô hình cây tăng cường và mạng nơ-ron học sâu trên cùng bài toán phân loại ý định mua hàng.

3.3.1 Logistic Regression

Logistic Regression là mô hình học máy có giám sát được sử dụng phổ biến trong các bài toán phân loại, đặc biệt là phân loại nhị phân. Khác với Linear Regression, Logistic Regression sử dụng hàm kích hoạt phi tuyến Sigmoid để chuyển đổi đầu ra của tổ hợp tuyến tính các đặc trưng thành xác suất nằm trong khoảng $(0, 1)$.

Với vector đầu vào $\mathbf{x} = [x_1, x_2, \ldots, x_k]^T$, mô hình tính tổng có trọng số của các đặc trưng thông qua vector trọng số $\mathbf{w} = [w_1, w_2, \ldots, w_k]^T$ và hệ số tự do b:

$$h(\mathbf{x}) = \mathbf{w}^T\mathbf{x} + b \tag{3}$$

Tiếp theo, giá trị $h(\mathbf{x})$ được đưa qua hàm kích hoạt phi tuyến Sigmoid nhằm ánh xạ đầu ra về khoảng $(0, 1)$:

$$\sigma(h) = \frac{1}{1 + e^{-h}} \tag{4}$$

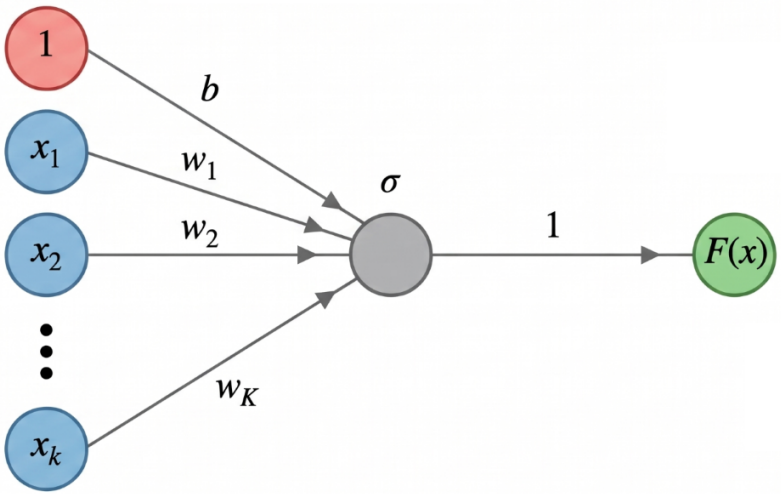
Hàm Sigmoid cho phép diễn giải đầu ra của mô hình dưới dạng xác suất. Do đó, hàm dự đoán cuối cùng của Logistic Regression được biểu diễn như sau:

$$\boxed{F(\mathbf{x}) = \sigma(\mathbf{w}^T\mathbf{x} + b) = \frac{1}{1 + e^{-(\mathbf{w}^T\mathbf{x}+b)}}} \tag{5}$$

Quá trình kết hợp các đặc trưng đầu vào qua trọng số, hệ số tự do và hàm Sigmoid được minh họa trong Hình 3.3.1.

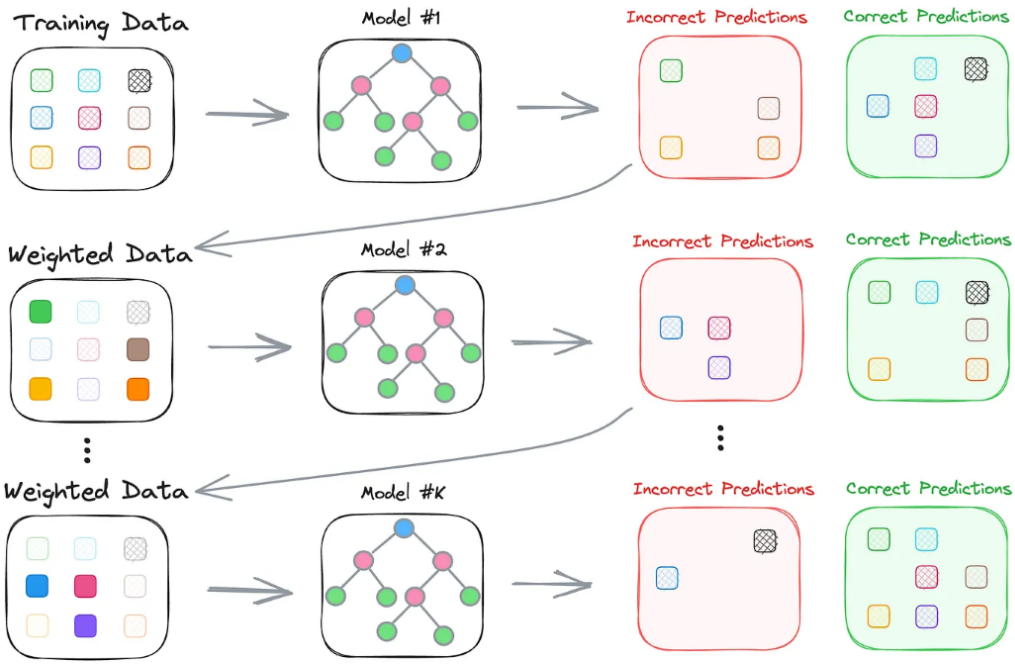
3.3.2 XGBoost

XGBoost là thuật toán học máy dựa trên phương pháp Gradient Boosting Decision Trees, sử dụng tập hợp nhiều cây quyết định (Decision Trees) để xây dựng mô hình dự đoán. Thay vì huấn luyện các cây độc lập, XGBoost xây dựng từng cây theo tuần tự, trong đó mỗi cây mới



Hình 3.3.1: Sơ đồ mô hình Logistic Regression với các đầu vào, trọng số và hàm Sigmoid

được bổ sung nhằm cải thiện những sai số còn tồn tại từ mô hình trước đó. Quá trình này giúp mô hình từng bước nâng cao khả năng dự đoán thông qua việc kết hợp kết quả từ nhiều cây. Quy trình bổ sung cây tuần tự và tập trung vào các dự đoán chưa chính xác được minh họa trong Hình 3.3.2.



Hình 3.3.2: Minh họa quy trình mô hình XGBoost qua các vòng huấn luyện

3.3.3 Multilayer Perceptron (MLP)

Multilayer Perceptron (MLP) là mô hình mạng nơ-ron truyền thẳng (Feedforward Neural Network), bao gồm nhiều lớp kết nối đầy đủ (Fully Connected Layers) nhằm học các mối quan hệ phi tuyến giữa các đặc trưng đầu vào. Thông qua các hàm kích hoạt phi tuyến, MLP có khả năng xây dựng những biểu diễn đặc trưng phức tạp, từ đó nâng cao khả năng phân biệt giữa

các lớp dữ liệu.

Trong nghiên cứu này, MLP được thiết kế với hai lớp ẩn có kích thước lần lượt là 16 và 8 nơ-ron. Tại mỗi lớp ẩn, đầu ra của phép biến đổi tuyến tính được đưa qua hàm kích hoạt ReLU (Rectified Linear Unit), được xác định như sau:

$$\mathrm{ReLU}(z) = \max(0, z) \tag{6}$$

Hàm ReLU giữ nguyên các giá trị dương và đưa các giá trị âm về 0, giúp mô hình học các quan hệ phi tuyến giữa các đặc trưng. Bên cạnh đó, kỹ thuật Dropout với tỷ lệ $p = 0.2$ được áp dụng sau mỗi lớp ẩn nhằm giảm hiện tượng overfitting. Trong quá trình huấn luyện, Dropout ngẫu nhiên vô hiệu hóa một tỷ lệ nơ-ron nhất định, giúp mô hình hạn chế sự phụ thuộc quá mức vào một số nơ-ron cụ thể.

Gọi $\mathbf{a}^{(l)}$ là vector đầu ra của lớp thứ l, $\mathbf{W}^{(l)}$ là ma trận trọng số và $\mathbf{b}^{(l)}$ là vector bias. Quá trình lan truyền tiến (Forward Propagation) qua mỗi lớp ẩn được biểu diễn như sau:

$$\mathbf{a}^{(l)} = \mathrm{Dropout}\left(\mathrm{ReLU}\left(\mathbf{W}^{(l)}\mathbf{a}^{(l-1)} + \mathbf{b}^{(l)}\right)\right) \tag{7}$$

Trong đó, $\mathbf{a}^{(0)} = \mathbf{x}$ là vector đặc trưng đầu vào.

Sau hai lớp ẩn, đầu ra được đưa qua lớp kết nối đầy đủ cuối cùng (Fully Connected Output Layer) với một nơ-ron, sau đó sử dụng hàm kích hoạt Sigmoid để chuyển đổi kết quả thành xác suất thuộc lớp dương:

$$\boxed{F(\mathbf{x}) = \sigma\left(\mathbf{W}^{(3)}\mathbf{a}^{(2)} + b^{(3)}\right) = \frac{1}{1 + e^{-\left(\mathbf{W}^{(3)}\mathbf{a}^{(2)} + b^{(3)}\right)}}} \tag{8}$$

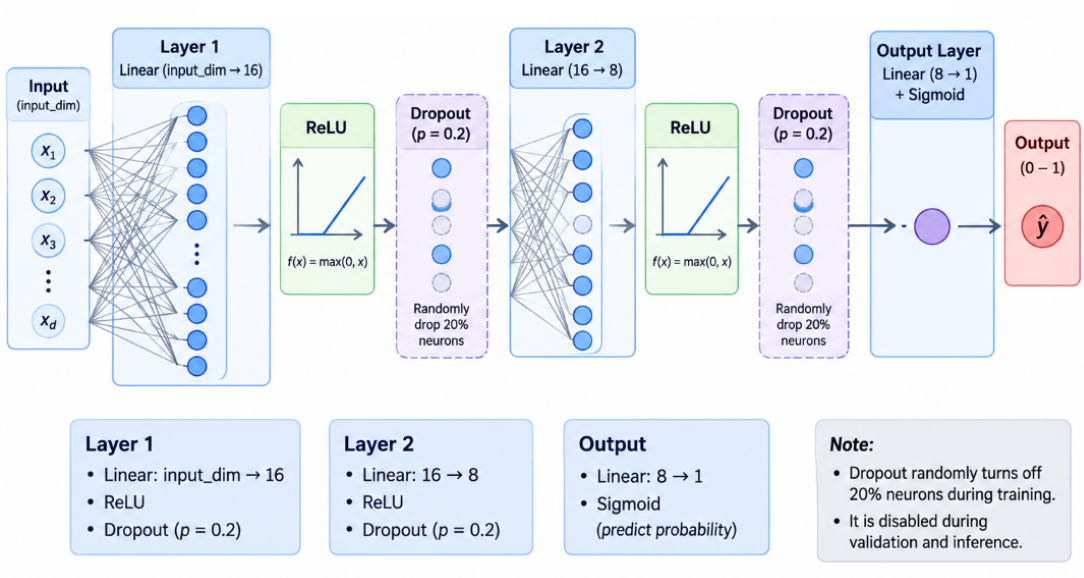
Trong đó, $F(\mathbf{x})$ biểu thị xác suất mẫu dữ liệu thuộc lớp 1. Tương tự Logistic Regression, mô hình sử dụng ngưỡng xác suất 0.5 để xác định nhãn dự đoán:

$$\hat{y} = \begin{cases} 1, & \text{nếu } F(\mathbf{x}) \geq 0.5, \\ 0, & \text{nếu } F(\mathbf{x}) < 0.5. \end{cases} \tag{9}$$

Kiến trúc MLP với hai lớp ẩn, ReLU, Dropout và lớp đầu ra Sigmoid được minh họa trong Hình 3.3.3.

3.4 Quy trình thực nghiệm

Để đánh giá riêng đóng góp của các bước tiền xử lý và kỹ thuật tạo đặc trưng, thực nghiệm được tổ chức thành bảy cấu hình tăng dần: từ đường cơ sở chỉ mã hóa biến phân loại, qua các bước chuẩn hóa và biến đổi Log1p, đến các cấu hình FE1–FE4 bổ sung đặc trưng theo từng nhóm. Số lượng biến đầu vào tăng từ 17 ở các cấu hình ban đầu lên 26 ở cấu hình FE4. Trình tự, số biến, thành phần kế thừa và phương pháp xử lý của từng cấu hình được tổng hợp trong Bảng 3.1.



Hình 3.3.3: Kiến trúc MLP gồm hai lớp ẩn với ReLU và Dropout, cùng lớp đầu ra Sigmoid

Bảng 3.1: **Bảng mô tả trình tự thực nghiệm**

STT	**Cấu hình thực nghiệm**	**Số biến**	**Thành phần kế thừa**	**Phương pháp xử lý / Bổ sung đặc trưng**
1	Basline (Raw, OHE)	17	Dữ liệu thô gốc	Không scale biến số. Chỉ mã hóa OHE cho 7 biến phân loại.
2	StandardScaler	17	17 biến gốc	Chuẩn hóa StandardScaler cho 10 biến số. OHE cho 7 biến phân loại.
3	Log1p + StandardScaler	17	17 biến gốc	Biến đổi log1p cho 5 biến phân phối lệch nặng (*Administrative*, *Administrative_Duration*, *ProductRelated*, *ProductRelated_Duration*, *PageValues*). StandardScaler cho 10 biến số, OHE cho 7 biến phân loại.
4	FE1	20	Log1p + Standard-Scaler	Bổ sung 3 biến: + `Has_PageValues` + `PV_per_TotalPages` + `PV_per_Duration`
5	FE2	22	FE1	Bổ sung 2 biến: + `PV_to_ExitRate` + `PV_x_NewVisitor`
6	FE3	25	FE2	Bổ sung 3 biến: + `ProdDur_to_ExitRate` + `Avg_Dur_per_Page` + `Admin_per_TotalPages`
7	FE4	26	FE3	Bổ sung 1 biến: + `Month_x_HasPV`

4 Evaluation Metrics

Hiệu quả của các mô hình được đánh giá thông qua năm độ đo: Accuracy, Precision, Recall, F1-score và Average Precision (AP). Các độ đo này phản ánh những khía cạnh khác nhau của khả năng phân loại, đặc biệt trong việc nhận diện các phiên truy cập có phát sinh mua hàng. Quy ước:

- TP (True Positive): Số phiên thực tế có mua hàng và được mô hình dự đoán đúng.
- TN (True Negative): Số phiên thực tế không mua hàng và được mô hình dự đoán đúng.
- FP (False Positive): Số phiên thực tế không mua hàng nhưng được mô hình dự đoán là có mua hàng.
- FN (False Negative): Số phiên thực tế có mua hàng nhưng được mô hình dự đoán là không mua hàng.

Các độ đo được xác định như sau:

- **Accuracy:** Tỷ lệ dự đoán đúng trên tổng số mẫu dữ liệu, phản ánh khả năng phân loại chính xác của mô hình trên cả hai lớp.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \tag{10}$$

- **Precision:** Tỷ lệ các phiên thực sự có mua hàng trong tổng số phiên được mô hình dự đoán là có mua hàng. Độ đo này phản ánh mức độ chính xác của các dự đoán thuộc lớp dương.

$$Precision = \frac{TP}{TP + FP} \tag{11}$$

- **Recall:** Tỷ lệ các phiên thực tế có mua hàng được mô hình nhận diện chính xác. Độ đo này phản ánh khả năng phát hiện đầy đủ các phiên mua hàng.

$$Recall = \frac{TP}{TP + FN} \tag{12}$$

- **F1-score:** Trung bình điều hòa giữa Precision và Recall, cung cấp một thước đo cân bằng giữa độ chính xác của dự đoán dương và khả năng nhận diện các mẫu thuộc lớp dương.

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall} \tag{13}$$

- **Average Precision (AP):** Độ đo tổng hợp hiệu suất của mô hình trên đường cong Precision-Recall (PR Curve), được tính bằng tổng Precision tại các ngưỡng phân loại, có

trọng số là mức tăng tương ứng của Recall.

$$AP = \sum_{n=1}^{N} (R_n - R_{n-1}) P_n \tag{14}$$

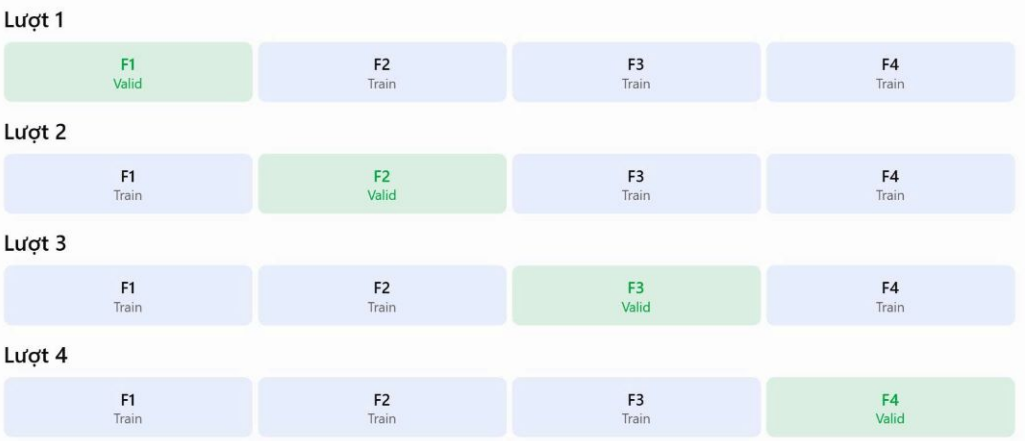
Trong đó, P_n và R_n lần lượt là Precision và Recall tại ngưỡng phân loại thứ n; N là số mức ngưỡng được xét và $R_0 = 0$.

5 Thực nghiệm

5.1 Phân chia dataset

Tập dữ liệu gồm 12,330 phiên được chia thành hai phần. Tập huấn luyện và kiểm định (Train & Valid) chiếm 80%, tương đương 9,864 phiên, trong đó tỷ lệ mua hàng là 15.47%. Tập kiểm tra (Test) chiếm 20%, tương đương 2,466 phiên, với tỷ lệ mua hàng là 15.49%.

Trên tập Train & Valid, áp dụng **RepeatedStratifiedKFold** với cấu hình `n_splits = 4` và `n_repeats = 3`. Phương pháp này duy trì tỷ lệ nhãn tương đối đồng đều giữa các fold, đồng thời lặp lại quá trình chia K-Fold nhiều lần để đánh giá độ ổn định của kết quả. Quy trình chia tập và kiểm chứng chéo được minh họa trong Hình 5.1.1.



Hình 5.1.1: Minh họa quy trình phân chia dữ liệu và kiểm chứng chéo K-Fold

5.2 Cấu hình huấn luyện và siêu tham số (Hyperparameters)

Để đảm bảo tính khách quan và so sánh công bằng tuyệt đối giữa các mô hình và cấu hình tiền xử lý, toàn bộ các siêu tham số huấn luyện chính được thiết lập cố định như sau:

5.2.1 Cấu hình Mạng PyTorch MLP

- ***Optimizer*:** Sử dụng Adam với tốc độ học khởi tạo lr = 0.002.
- ***Weight Decay*:** Áp dụng điều chuẩn L_2 với hệ số $\lambda = 10^{-3}$.

- ***Loss Function*:** Binary Cross-Entropy Loss (`BCELoss`).
- **Batch size & Số Epochs:** batch_size = 128; số epoch huấn luyện tối đa là epochs = 50.
- ***Early Stopping*:** Dùng 20% tập Train làm validation; dừng khi val loss không cải thiện sau 8 epochs.
- ***Random Seed*:** Cố định seed = 42 nhằm bảo đảm tính tái lập hoàn toàn của trọng số khởi tạo ban đầu.

5.2.2 Cấu hình Logistic Regression (LR)

- **Thuật toán tối ưu:** Sử dụng `lbfgs` với điều chuẩn Ridge (L_2, nghịch đảo cường độ $C = 1.0$).
- **Số vòng lặp tối đa:** `max_iter` = 1000.
- ***Random Seed*:** Cố định seed = 42.

5.2.3 Cấu hình XGBoost (XGBClassifier)

- **Cấu trúc cây:** Độ sâu tối đa `max_depth` = 6; số lượng cây `n_estimators` = 100.
- **Tốc độ học:** learning_rate = 0.3;
- **Xử lý biến & Seed:** Kích hoạt `enable_categorical` = True và cố định seed = 42.

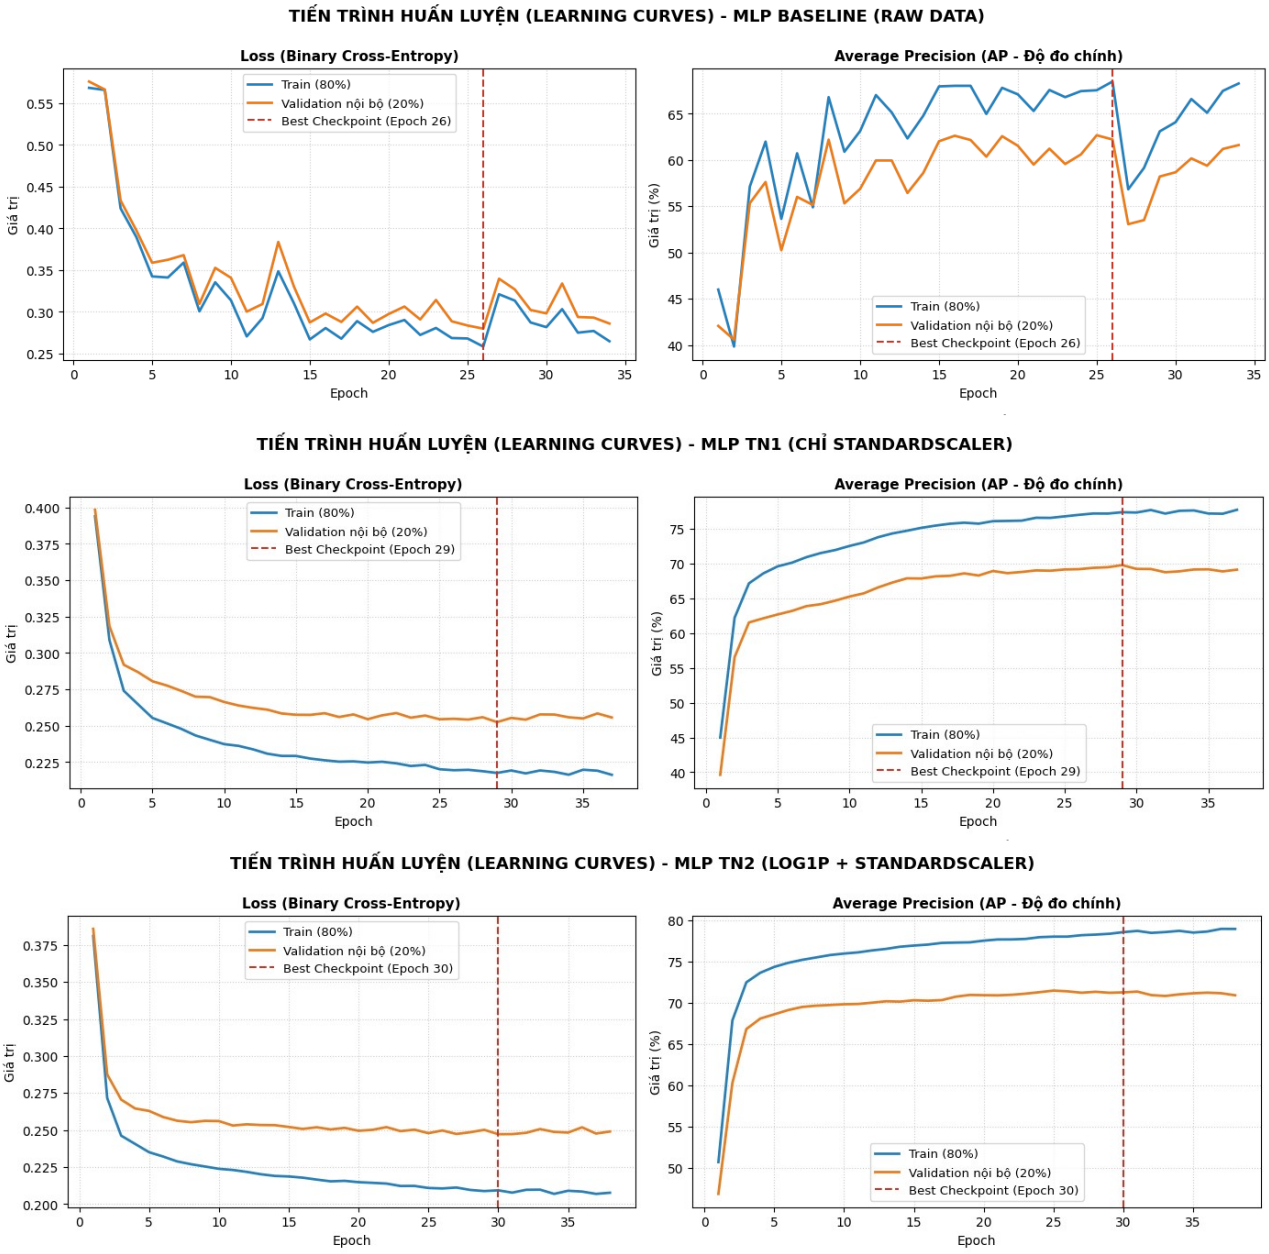
5.3 Kết quả thực nghiệm

5.3.1 Phân tích quá trình hội tụ của MLP qua các phương pháp tiền xử lý

Dựa trên đường cong huấn luyện qua từng epoch của ba thiết lập tiền xử lý dữ liệu, có thể ghi nhận những khác biệt sau:

- **Baseline:** Với dữ liệu thô, sự chênh lệch lớn về thang đo giữa các biến khiến mô hình khó hội tu trong quá trình huấn luyện. Cả hai đường Loss và AP đều dao động mạnh qua từng epoch, khiến quá trình huấn luyện dừng sớm tại **Epoch 26**, với AP validation chỉ đạt khoảng $62\% - 63\%$.
- **Chỉ StandardScaler:** Phép chuẩn hóa Z-score giúp các biến có thang đo đồng nhất, cải thiện đáng kể độ ổn định của quá trình huấn luyện. Đường Loss giảm ổn định, trong khi AP tăng dần và đạt *Best Checkpoint* tại **Epoch 29**, với AP validation vượt mốc 70%.
- **Kết hợp Log1p và StandardScaler:** Phép biến đổi $\log(1 + x)$ giúp giảm ảnh hưởng của các giá trị ngoại lai lớn, từ đó cải thiện quá trình học của mô hình. Mô hình hội tụ nhanh và ổn định, đạt *Best Checkpoint* tại **Epoch 30**, với AP validation cao nhất (khoảng $71.5\% - 72\%$).

Chuẩn hóa thang đo (StandardScaler) đóng vai trò điều kiện tiên quyết giúp quá trình tối ưu gradient của mạng nơ-ron hội tụ mượt mà; trong khi phép biến đổi log1p đóng vai trò bổ trợ giúp nén ngoại lai để tối đa hóa hiệu năng (Hình 5.3.1).



Hình 5.3.1: Đường cong Loss và AP của MLP theo các thiết lập tiền xử lý

5.3.2 Thời gian huấn luyện

Để đảm bảo có thể so sánh thời gian huấn luyện một cách công bằng, cả ba mô hình được thực nghiệm trên cùng một quy trình tiền xử lý dữ liệu (Log1p và StandardScaler) với lý do đảm bảo mô hình MLP có thể hội tụ ổn định và tạo nền tảng cho các kỹ thuật kỹ thuật feature engineering phía sau. Dựa trên kết quả đo lường thời gian huấn luyện ở Bảng 5.1, có thể rút ra một số nhận xét chính:

- **Thời gian huấn luyện và độ chính xác:** Logistic Regression và XGBoost có tốc độ

Bảng 5.1: So sánh thời gian huấn luyện và hiệu năng trên tập Test giữa các mô hình trên cùng thiết lập Log1p và StandardScaler

Mô hình	Phần cứng	Vòng lặp / Epochs	Thời gian / Epoch	Tổng thời gian (s)	Test AP (%)
Logistic Regression	CPU	1000 iter	—	0.35	69.50
XGBoost	CPU	100 trees	—	0.40	72.40
MLP	CPU	38 epochs	0.310 s/epoch	11.77	**75.49**
MLP	GPU (T4)	50 epochs	0.364 s/epoch	18.22	75.14

huấn luyện gần như tức thì (0.35s−0.40s). Trong khi đó, MLP (huấn luyện bằng PyTorch) đòi hỏi thời gian huấn luyện dài hơn khoảng 30 lần (11.77s trên CPU), nhưng đổi lại đạt Test AP cao nhất (75.49%), cao hơn XGBoost 3.09 điểm phần trăm và Logistic Regression 5.99 điểm phần trăm.

- **Hiệu quả phần cứng CPU và GPU cho MLP:** Thời gian mỗi epoch trên CPU và GPU Tesla T4 tương đương ($\approx 0.31\text{s} - 0.36\text{s}$/epoch). Với mạng MLP nhỏ (1.249 tham số) và dữ liệu dạng bảng quy mô nhỏ, GPU chưa mang lại sự cải thiện đáng kể về mặt thời gian.
- **Ảnh hưởng của Early Stopping:** MLP trên CPU dừng sau 38 epochs (11.77s), trong khi cấu hình GPU chạy đủ 50 epochs (18.22s). Với các số liệu này, CPU là lựa chọn phù hợp hơn về thời gian và chi phí cho bài toán.

5.3.3 So sánh kết quả các mô hình

Sáu bảng kết quả thực nhiệm của ba mô hình được chia thành hai nhóm để thuận tiện so sánh. Bảng 5.2–5.4 trình bày kết quả Cross Validation của XGBoost, Logistic Regression và MLP; các giá trị AP được báo cáo dưới dạng trung bình và độ lệch chuẩn qua các lần đánh giá, cùng với F1 của từng lớp và F1 macro. Bảng 5.5–5.7 tổng hợp kết quả trên tập Test độc lập, bao gồm AP, F1 và Accuracy.

Trong các bảng, cấu hình có tên `Z-score` dùng tên rút gọn thay cho `StandardScaler`; cả hai cùng chỉ phép chuẩn hóa z-score theo trung bình và độ lệch chuẩn. Chỉ số ΔAP là mức chênh lệch AP của cấu hình so với Baseline, tính theo điểm phần trăm. Riêng các bảng Cross Validation, $N_{\Delta AP>0}$ cho biết số lần đánh giá mà AP của cấu hình cao hơn Baseline tương ứng. Với 4 fold và 3 lần lặp (repeat), tổng cộng có $4 \times 3 = 12$ lần đánh giá; do đó, số đếm này được tính trên tối đa 12 lần.

Để quan sát xu hướng thay đổi qua các cấu hình, Hình 5.3.2 minh họa AP và F1 lớp Mua của ba mô hình trên Cross Validation, còn Hình 5.3.3 thể hiện các độ đo tương ứng trên tập Test.

Bảng 5.2: **Kết quả XGBoost trên Cross Validation**

Cấu hình	**Số biến**	**CV AP (%)**	**ΔAP (%)** ($N_{\Delta AP>0}$)	**F1 nhãn 0 (%)**	**F1 nhãn 1 (%)**	**F1 macro (%)**
Baseline	17	71.21 ± 1.85	–	93.86 ± 0.34	63.38 ± 1.67	78.62 ± 0.85
Z-score	17	71.70 ± 1.97	+0.49 (6/12)	93.86 ± 0.36	63.37 ± 1.50	78.61 ± 0.92
Log1p + Z-score	17	71.70 ± 1.97	+0.49 (7/12)	93.86 ± 0.36	63.37 ± 1.50	78.61 ± 0.92
FE1	20	71.18 ± 1.90	-0.03 (6/12)	93.90 ± 0.36	63.53 ± 2.02	78.71 ± 1.16
FE2	22	72.08 ± 1.77	+0.87 (9/12)	93.87 ± 0.35	63.59 ± 1.74	78.73 ± 1.02
FE3	25	72.00 ± 1.87	+0.79 (7/12)	93.91 ± 0.37	63.60 ± 1.94	78.75 ± 1.13
FE4	26	72.24 ± 1.69	+1.03 (8/12)	93.99 ± 0.32	64.06 ± 1.81	79.02 ± 1.05

Bảng 5.3: **Kết quả Logistic Regression trên Cross Validation**

Cấu hình	**Số biến**	**CV AP (%)**	**ΔAP (%)** ($N_{\Delta AP>0}$)	**F1 nhãn 0 (%)**	**F1 nhãn 1 (%)**	**F1 macro (%)**
Baseline	17	63.54 ± 2.63	–	93.24 ± 0.28	49.45 ± 1.95	71.35 ± 1.11
Z-score	17	63.74 ± 2.58	+0.20 (8/12)	93.32 ± 0.29	50.00 ± 2.37	71.66 ± 1.30
Log1p + Z-score	17	68.15 ± 2.07	+4.61 (12/12)	93.81 ± 0.33	61.79 ± 1.82	77.80 ± 1.05
FE1	20	71.33 ± 2.24	+7.79 (12/12)	94.06 ± 0.38	64.03 ± 2.24	79.04 ± 1.30
FE2	22	71.99 ± 1.99	+8.45 (12/12)	94.13 ± 0.42	64.21 ± 2.38	79.17 ± 1.39
FE3	25	72.24 ± 1.98	+8.70 (12/12)	94.15 ± 0.39	64.49 ± 2.22	79.32 ± 1.28
FE4	26	73.22 ± 1.80	+9.68 (12/12)	94.13 ± 0.22	64.56 ± 1.48	79.35 ± 0.81

Bảng 5.4: **Kết quả MLP trên Cross Validation**

Cấu hình	**Số biến**	**CV AP (%)**	**ΔAP (%)** ($N_{\Delta AP>0}$)	**F1 nhãn 0 (%)**	**F1 nhãn 1 (%)**	**F1 macro (%)**
Baseline	17	66.16 ± 2.07	–	93.32 ± 0.33	48.05 ± 7.34	70.69 ± 3.67
Z-score	17	71.62 ± 1.98	+5.46 (12/12)	94.01 ± 0.35	63.24 ± 2.89	78.62 ± 1.46
Log1p + Z-score	17	73.59 ± 1.52	+7.43 (12/12)	94.12 ± 0.29	64.53 ± 1.59	79.33 ± 0.81
FE1	20	74.45 ± 1.53	+8.29 (12/12)	94.26 ± 0.27	65.90 ± 1.89	80.08 ± 0.95
FE2	22	74.39 ± 1.34	+8.23 (12/12)	94.20 ± 0.33	64.82 ± 1.72	79.51 ± 0.88
FE3	25	74.33 ± 1.56	+8.17 (12/12)	94.19 ± 0.36	65.40 ± 2.22	79.79 ± 1.12
FE4	26	73.84 ± 1.75	+7.68 (12/12)	94.12 ± 0.36	65.29 ± 2.21	79.70 ± 1.12

Bảng 5.5: **Kết quả XGBoost trên Test**

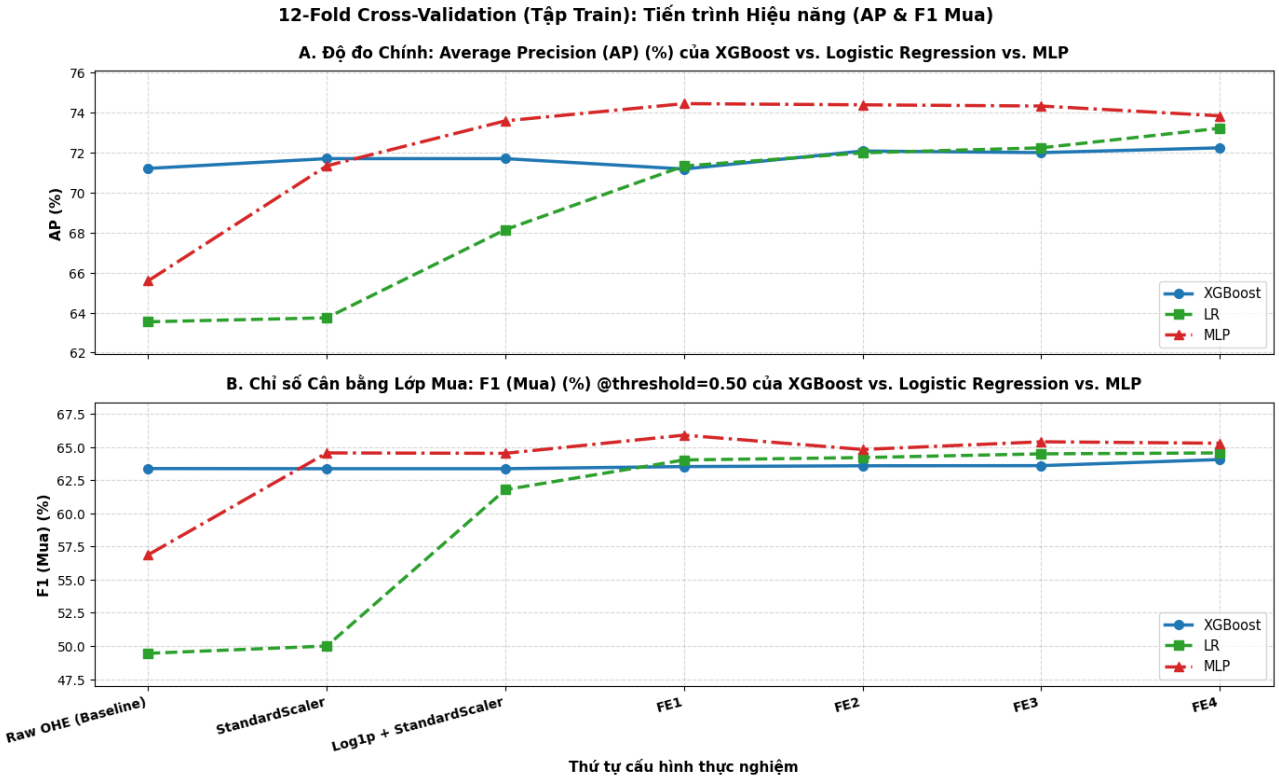
Cấu hình	**Số biến**	**Test AP (%)**	**ΔAP (%)**	**F1 nhãn 0 (%)**	**F1 nhãn 1 (%)**	**F1 macro (%)**	**Accuracy (%)**
Baseline	17	71.94	–	93.88	64.44	79.16	89.55
Z-score	17	72.42	+0.48	93.73	63.60	78.67	89.31
Log1p + Z-score	17	72.42	+0.48	93.73	63.60	78.67	89.31
FE1	20	71.34	-0.60	93.96	65.38	79.67	89.72
FE2	22	72.40	+0.46	93.94	65.19	79.57	89.68
FE3	25	73.49	+1.55	94.34	66.95	80.64	90.33
FE4	26	71.32	-0.62	94.05	65.27	79.66	89.84

Bảng 5.6: **Kết quả Logistic Regression trên Test**

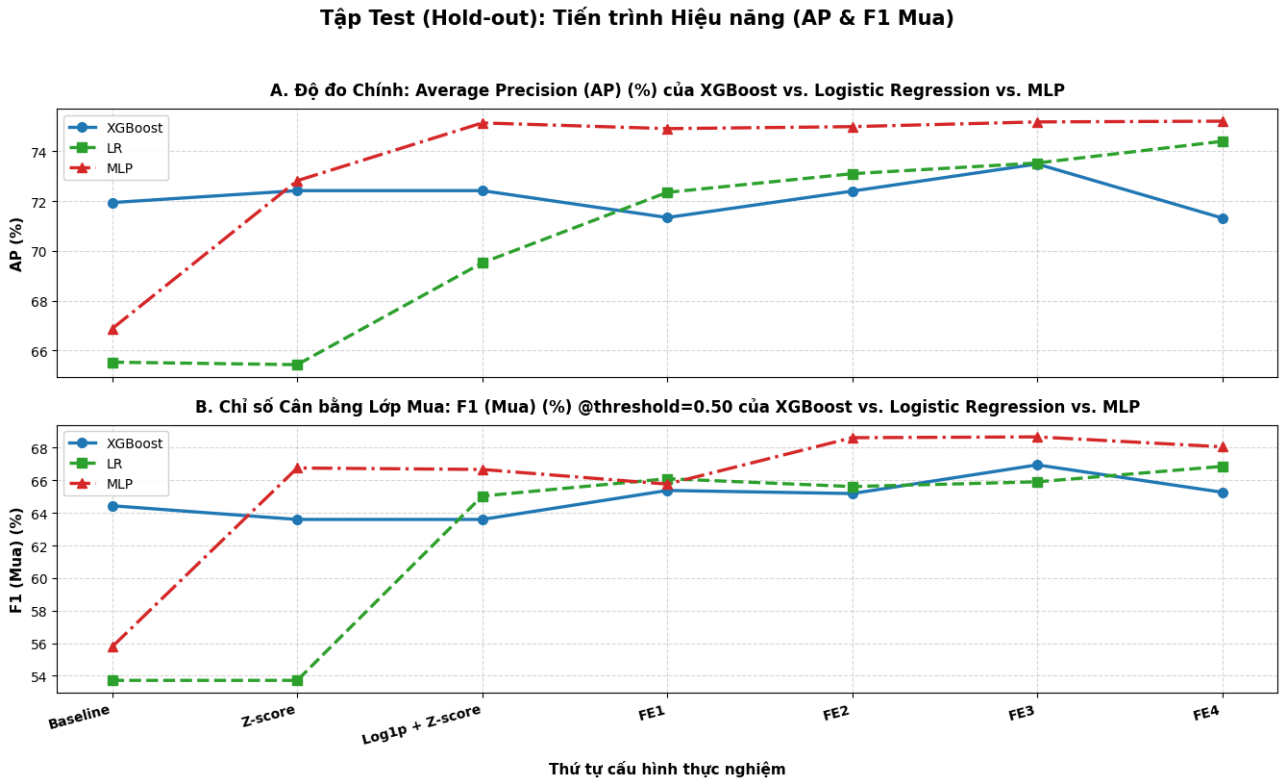
Cấu hình	Số biến	Test AP (%)	ΔAP (%)	F1 nhãn 0 (%)	F1 nhãn 1 (%)	F1 macro (%)	Accuracy (%)
Baseline	17	65.53	–	93.61	53.72	73.66	88.78
Z-score	17	65.43	-0.10	93.61	53.72	73.66	88.78
Log1p + Z-score	17	69.52	+3.99	94.17	65.04	79.61	90.00
FE1	20	72.35	+6.82	94.25	66.10	80.18	90.17
FE2	22	73.10	+7.57	94.21	65.62	79.92	90.09
FE3	25	73.53	+8.00	94.23	65.91	80.07	90.13
FE4	26	74.40	+8.87	94.51	66.86	80.68	90.58

Bảng 5.7: **Kết quả MLP trên Test**

Cấu hình	Số biến	Test AP (%)	ΔAP (%)	F1 nhãn 0 (%)	F1 nhãn 1 (%)	F1 macro (%)	Accuracy (%)
Baseline	17	66.88	–	93.65	55.79	74.72	88.90
Z-score	17	72.82	+5.94	94.12	66.76	80.44	90.00
Log1p + Z-score	17	75.14	+8.26	94.60	66.67	80.63	90.70
FE1	20	74.91	+8.03	94.54	65.77	80.16	90.58
FE2	22	74.99	+8.11	94.60	68.62	81.61	90.78
FE3	25	75.18	+8.30	94.76	68.67	81.72	91.03
FE4	26	75.21	+8.33	94.47	68.06	81.26	90.58



Hình 5.3.2: Diễn biến kết quả Cross Validation của ba mô hình qua các cấu hình thực nghiệm



Hình 5.3.3: Diễn biến kết quả Test của ba mô hình qua các cấu hình thực nghiệm

6 Kết luận

Dựa trên chuỗi thử nghiệm từ mô hình cơ sở (*Baseline*) đến các cấu hình bổ sung đặc trưng (*Feature Engineering*), nghiên cứu đánh giá ba mô hình Logistic Regression (LR), Multi-Layer Perceptron (MLP) và XGBoost theo mức độ cải thiện hiệu năng, độ ổn định qua kiểm chứng chéo và tác động của các bước tiền xử lý. Kết quả cho thấy không có một cấu hình duy nhất tốt nhất trên mọi độ đo: MLP đạt Test AP cao nhất, LR cải thiện mạnh nhất so với đường cơ sở, còn XGBoost duy trì hiệu năng tốt với mức tăng vừa phải.

6.1 Mức độ cải thiện và tính ổn định

Kết quả trên tập kiểm thử độc lập (*Hold-out Test*) và kiểm chứng chéo 12-fold (*12-Fold Cross-Validation*) cho thấy mức cải thiện khác nhau giữa các mô hình:

- **Cải thiện trên tập Test (Test AP và F1 lớp Mua):**
  - *Logistic Regression:* Test AP tăng từ 65.53% ở Baseline lên 74.40% tại FE4, tương đương 8.87 điểm phần trăm. F1 lớp Mua tăng từ 53.72% lên 66.86%, tương đương 13.14 điểm phần trăm. Kết quả cho thấy biến đổi dữ liệu và đặc trưng phái sinh giúp LR nắm bắt tốt hơn tín hiệu hành vi trong dữ liệu.
  - *MLP:* Đạt Test AP cao nhất là 75.21% tại FE4, tăng 8.33 điểm phần trăm so với Baseline (66.88%). F1 lớp Mua cao nhất là 68.67% tại FE3, tăng 12.88 điểm phần trăm so với Baseline (55.79%). Hai độ đo tốt nhất xuất hiện ở hai cấu hình khác nhau, vì vậy lựa chọn cấu hình cần căn cứ vào mục tiêu đánh giá.
  - *XGBoost:* Test AP cao nhất tại FE3, đạt 73.49% so với 71.94% ở Baseline, tăng 1.55 điểm phần trăm. F1 lớp Mua cũng tăng từ 64.44% lên 66.95%, tương đương 2.51 điểm phần trăm. Mức cải thiện nhỏ hơn LR và MLP, phù hợp với khả năng của mô hình cây trong việc học các ngưỡng và quan hệ phi tuyến từ dữ liệu.
- **Độ ổn định qua 12 folds:** Độ lệch chuẩn của CV AP cho thấy mức dao động giữa các folds và khác nhau theo từng cấu hình:
  - Với MLP, độ lệch chuẩn thấp nhất là $\pm 1.34\%$ tại FE2, so với $\pm 2.07\%$ ở Baseline.
  - Với LR, độ lệch chuẩn giảm từ $\pm 2.63\%$ ở Baseline xuống $\pm 1.80\%$ tại FE4.
  - Với XGBoost, độ lệch chuẩn tại FE4 là $\pm 1.69\%$, thấp hơn mức $\pm 1.85\%$ ở Baseline; tuy nhiên, độ lệch chuẩn tăng nhẹ ở một số cấu hình trung gian.

6.2 Tác động của tiền xử lý và các nhóm đặc trưng

Kết quả thực nghiệm cho thấy tác động của tiền xử lý và tạo đặc trưng phụ thuộc vào từng mô hình:

1. **Logistic Regression — cải thiện nhờ biến đổi và đặc trưng phái sinh:**

- Kết hợp Log1p và Z-score làm CV AP tăng 4.61 điểm phần trăm, từ 63.54% lên 68.15%; F1 lớp Mua tăng từ 49.45% lên 61.79%. Việc giảm độ lệch của các biến có đuôi dài giúp dữ liệu phù hợp hơn với mô hình tuyến tính.
- Các cấu hình FE tiếp tục cải thiện kết quả; FE4 đạt Test AP 74.40% và F1 lớp Mua 66.86%, là mức cao nhất của LR trong các cấu hình được so sánh. Các biến FE1 mô tả mật độ PageValues, còn FE4 bổ sung tương tác với bối cảnh tháng, góp phần cung cấp thêm tín hiệu cho mô hình.

2. **MLP — cải thiện đáng kể từ chuẩn hóa:**

- Log1p kết hợp Z-score nâng CV AP từ 66.16% ở Baseline lên 73.59%, tăng 7.43 điểm phần trăm; F1 lớp Mua tăng từ 48.05% lên 64.53%. Chuẩn hóa thang đo giúp quá trình tối ưu mạng nơ-ron ổn định hơn.
- Các đặc trưng FE tiếp tục nâng một số độ đo: FE3 đạt F1 lớp Mua cao nhất (68.67%), trong khi FE4 đạt Test AP cao nhất (75.21%). Điều này cho thấy cấu hình tối ưu phụ thuộc vào việc ưu tiên AP hay khả năng nhận diện lớp Mua.

3. **XGBoost — lợi ích chủ yếu đến từ đặc trưng mới:**

- Các phép chuẩn hóa và Log1p chỉ tạo thay đổi nhỏ: CV AP tăng từ 71.21% ở Baseline lên 71.70% với Z-score; Test AP tăng từ 71.94% lên 72.42%. Mức cải thiện này thấp hơn so với LR và MLP.
- FE3 đạt kết quả Test tốt nhất của XGBoost với AP 73.49% và F1 lớp Mua 66.95%.

Tóm lại, MLP đạt Test AP cao nhất, LR có mức tăng so với Baseline lớn nhất, còn XGBoost đạt kết quả Test tốt nhất tại FE3. Vì vậy, cấu hình lựa chọn nên gắn với mục tiêu ứng dụng: tối ưu AP tổng thể, tăng khả năng nhận diện lớp Mua, hoặc ưu tiên độ ổn định qua các folds.